

Assistant IA — Observatoire de Population de Ouagadougou (OPO)

Rapport technique : conception d'un agent RAG et d'un module d'analyse de données démographiques

Auteur	Mohamed Lamine Sawadogo
Date	29 juillet 2026
Statut	Prototype interne — usage équipe OPO
Version	1.0

Ce document décrit l'architecture, la méthodologie et les limites du prototype d'assistant développé pour l'équipe de l'Observatoire de Population de Ouagadougou : un agent capable de répondre aux questions sur le dictionnaire de données (approche RAG), et d'analyser toute table déposée pour produire un indicateur, un échantillon reproductible ou un rapport de cohérence.

1. Contexte et objectifs

L'OPO exploite une base de suivi démographique structurée en 23 tables et 327 variables (unités suivies, épisodes, événements démographiques, historiques individuels). L'équipe a exprimé le besoin d'un assistant interne capable de :

- répondre aux questions sur la signification des variables à partir du dictionnaire de données ;
- calculer un indicateur ou extraire un échantillon reproductible à partir d'une table réelle, quelle que soit sa structure exacte ;
- détecter les incohérences à travers les identifiants individuels (doublons, filiations orphelines, dates invraisemblables) sans jamais appliquer de correction automatique ;
- générer, à la demande, la syntaxe R ou Stata correspondante ;
- restreindre l'usage à l'équipe, avec une distinction entre les personnes pouvant uniquement consulter (indicateurs, échantillons, syntaxes) et celles habilitées à valider une correction.

2. Architecture du système

Le système suit deux chemins distincts selon la nature de la question, afin de limiter le risque d'hallucination sur les résultats chiffrés :

Chemin 1 — Questions documentaires (dictionnaire de données)



Chemin 2 — Analyse d'une table (calcul direct, sans hallucination possible)



Le chemin 1 (questions documentaires) passe par une recherche vectorielle dans le dictionnaire puis par un modèle de langage, avec obligation de répondre uniquement à partir du contexte récupéré. Le chemin 2 (analyse de données) ne fait jamais appel au LLM pour produire un chiffre : le calcul est effectué directement par du code (pandas), ce qui élimine le risque d'un indicateur halluciné.

3. Méthodologie

3.1 Corpus et chunking

Le dictionnaire Excel source (23 tables, 327 variables) est converti automatiquement en 24 documents texte, un par table. Chaque ligne du dictionnaire (une variable) devient un chunk autonome, préfixé du nom, du titre et de la description de sa table d'origine — ce qui lui permet de rester interprétable même isolé de son contexte d'origine lors de la récupération.

3.2 Choix de la vectorisation : TF-IDF plutôt qu'embeddings neuronaux

Le prototype utilise une vectorisation TF-IDF (scikit-learn) plutôt que des embeddings sémantiques (sentence-transformers). Ce choix est justifié par la taille du corpus (environ 350 chunks, un dictionnaire de données au vocabulaire technique stable), par l'absence de dépendance à un modèle à télécharger (fonctionnement hors ligne, déploiement plus léger), et par la nature du besoin : retrouver la définition exacte d'une variable nommée est un problème lexical plus que sémantique. Un test en conditions réelles (question : « que signifie fatherid dans Tindividual ? ») confirme que le chunk exact remonte en première position. Une migration vers des embeddings neuronaux reste possible si les questions deviennent plus reformulées ou portent sur un corpus plus large et moins structuré (voir section 5).

3.3 Modèle de langage

Le fournisseur de LLM est interchangeable (Groq ou Claude/Anthropic), configuré par une clé d'API saisie dans l'interface. Le prompt système impose explicitement de répondre uniquement à partir des extraits récupérés et de déclarer une absence d'information plutôt que d'inventer une réponse.

3.4 Analyse générique des tables déposées

Le module d'analyse ne suppose aucun schéma figé : les colonnes d'identifiant sont détectées par leur nom (motif « id »/« identif »), les colonnes de date par leur type ou par un test de parsing réussi sur plus de 70% des valeurs. Cette approche permet de traiter une table dont les colonnes ne correspondent pas exactement au dictionnaire de référence.

3.5 Garde-fous de confidentialité et de gouvernance

- Toute colonne dont le nom évoque un nom/prénom (nom, name, prénom, surname...) est retirée automatiquement avant toute analyse, même si elle est présente dans le fichier source.
- Aucune correction n'est appliquée automatiquement : les contrôles de cohérence produisent uniquement une liste d'identifiants suspects, à valider par une personne habilitée.
- La distinction entre profil « Consultation » et profil « Correction » est prévue au niveau de la gestion des comptes (projets séparés), pas dans la logique de l'agent lui-même.

4. Validation et tests

Le pipeline a été testé de bout en bout sur le dictionnaire réel de l'OPO : construction de l'index (352 chunks, 24 documents), récupération pertinente sur des questions ciblées, et détection correcte d'anomalies injectées volontairement (doublon d'identifiant, date postérieure à aujourd'hui, date antérieure à 1900) sur un jeu de données synthétique. Une suite de tests automatisés (pytest) couvre les fonctions critiques du module d'analyse et de récupération documentaire, afin de garantir que toute modification future du code ne régresse pas silencieusement.

5. Limites et perspectives

Recherche lexicale plutôt que sémantique

Le TF-IDF retrouve mal une question très reformulée par rapport au vocabulaire du dictionnaire. Perspective : embeddings sentence-transformers si le besoin s'en fait sentir.

Détection d'intention par mots-clés

Le routage entre question documentaire et demande d'analyse de table repose sur des mots-clés simples dans l'interface, pas sur une compréhension complète de la question. Perspective : fonction calling côté LLM pour un routage plus robuste.

Absence d'authentification intégrée

Le prototype ne gère pas de comptes utilisateurs. Pour un déploiement partagé avec des droits différenciés, une couche d'authentification est nécessaire avant toute mise en ligne (ou usage via un espace Claude Team/Enterprise, qui gère nativement les comptes et le partage restreint).

Rapprochement nominal exclu de l'agent

La détection de doublons par similarité de nom (même personne sous deux identifiants) est volontairement laissée à un script séparé, exécuté hors de l'agent, pour ne jamais exposer de données nominatives au modèle de langage.

6. Conclusion

Le prototype répond aux besoins exprimés par l'équipe OPO — consultation du dictionnaire, calcul d'indicateurs, échantillonnage reproductible, détection de cohérence, génération de syntaxe R/Stata — avec une architecture volontairement simple et vérifiable, où le calcul chiffré ne dépend jamais d'un modèle de langage. Les limites identifiées sont connues et documentées, avec des pistes d'évolution concrètes pour chacune.